Quelle est la probabilité d'une image ? Densités normalisées par score matching dual

Travaux pratiques sur article

Master TRIED — Aymeric Chazottes

Contexte

Le problème. Quelle est la probabilité d'une image ? Un modèle de probabilité des images servirait à beaucoup de choses (compression, détection d'images atypiques, problèmes inverses), mais l'apprendre est réputé impossible : la densité $p(x)$ vit en dimension d égale au nombre de pixels, et l'estimer sans hypothèse demanderait un nombre d'exemples exponentiel en d. Il y a deux obstacles. L'un est *statistique* : il faut des a priori forts (des biais inductifs), en pratique ceux d'une architecture de réseau. L'autre est *calculatoire* : un modèle $p_\theta(x) = e^{-U_\theta(x)}/Z_\theta$ demande la constante $Z_\theta = \int e^{-U_\theta}$, une intégrale en dimension d.

Ce que font les modèles de diffusion. Ils contournent les deux obstacles en apprenant non pas la densité mais son *score* $\nabla \log p$, qui ne dépend pas de Z, à tous les niveaux de bruit, par débruitage. Ils produisent des images remarquables, mais leur densité reste implicite : l'évaluer demande d'intégrer le long d'une trajectoire, à grand coût.

L'article. Guth, Kadkhodaie et Simoncelli [1] apprennent directement une énergie $U_\theta(y, t)$, fonction de l'image bruitée y et de la variance du bruit t, en ajustant ses *deux* dérivées : le score d'espace $\nabla_y U_\theta$ (débruitage, comme les modèles de diffusion) et le score de temps $\partial_t U_\theta$ (objectif nouveau). C'est le *score matching dual*. L'énergie, calculée par un réseau construit à partir d'un débruiteur UNet, est normalisée et s'évalue en une seule passe. Les auteurs l'utilisent pour mesurer la probabilité des images d'ImageNet, et trouvent des résultats inattendus : des probabilités qui s'étalent sur un facteur $10^{14\,000}$, distribuées selon une loi de Gumbel, et une dimension locale qui dépend de l'image.

Le TP. On reprend ce raisonnement : ce qui manque au score (partie 2), l'objectif dual (partie 3), l'architecture (partie 4), la validation du modèle (partie 5), puis ce qu'il dit des images : leurs probabilités (parties 6 et 7) et leur dimension locale (partie 8).

Organisation

Gestion du temps. Les deux séances sont denses : elles demandent de ne pas perdre de temps. Lancez les notebooks longs dès le début de la partie concernée et traitez les questions « à la main » pendant qu'ils tournent. En cas de besoin, l'arbitrage est indiqué : les sous-questions marquées « (priorité réduite) » passent après les autres ; admettez alors leur résultat et poursuivez.

Données à télécharger. Rien n'est téléchargé sans votre accord, en dehors de la cellule d'installation.

- *Cellule d'installation* (première cellule de chaque notebook, à exécuter en premier) : sur Colab, elle télécharge seulement le code, le module `tp/tp_outils.py`, les poids du réseau utilisé (35 Mo par réseau) et les résultats pré-calculés des auteurs dont le notebook a besoin.
- *Cellule « Données »* (juste après) : les images de validation d'ImageNet64 (50 000 images, 417 Mo depuis un miroir HuggingFace, puis quelques minutes de décodage), enregistrées dans `data/`. Elle ne fait rien par défaut : au premier lancement, remplacez `if False:` par `if True:` et exécutez-la. En local, une fois pour toutes ; sur Colab, à chaque nouvelle session (le disque est effacé). Notebooks concernés : `TP_reseau_energie`, `TP_log_probabilites`, `TP_dimension_effective`, `TP_entrainement_dual`

; `TP_melange_gaussien` n'utilise pas d'images. Les notebooks des auteurs `cross_entropy`, `energy_histogram`, `affine_and_sparsity` et `dimensionality` (versions `_colab`) demandent en plus le premier fragment des images d'entraînement (483 Mo), soit 900 Mo.

Le travail se fait dans les notebooks du dépôt forké (`https://github.com/ach0000/DualScoreMatching`), qui s'ouvrent dans Colab par leur bouton « Open in Colab » (liste dans `tp/README.md`). Chaque notebook commence par une cellule d'installation à exécuter en premier : sur Colab, elle télécharge seulement les fichiers dont le notebook a besoin ; en local, elle rend le code importable. Les notebooks `TP_*` (dossier `tp/`) s'appuient sur le module `tp/tp_outils.py` (voir sa documentation par `help`), qui complète le code des auteurs sans le modifier ; ils ont un profil réduit, utilisé par défaut sur CPU comme sur GPU, et un profil GPU (réglages des auteurs, non vérifié), qui s'active en remplaçant `if False:` par `if True:` dans la cellule de réglages. Les notebooks des auteurs, adaptés pour Colab, reproduisent les figures de l'article à l'échelle ; leurs originaux (racine du dépôt) ne sont pas modifiés, les versions adaptées sont dans `tp/auteurs/`, sous le même nom complété de `_colab` (par exemple `simple_example_colab`).

Notebook	Profil réduit (durée CPU)	Profil GPU	Notebook des auteurs (version `_colab`)	Parties
`TP_melange_gaussien`	6 min	20 000 itér.	`simple_example`	2
`TP_reseau_energie`	2 min	plus d'images	`denoiser_vs_energy`	4, 5
`TP_log_probabilites`	6 min (5 000 images)	50 000 images	`energy_histogram`, `cross_entropy`, `affine_and_sparsity`, `generalization`	5 à 7
`TP_dimension_effective`	2 min (6 images)	15 images	`dimensionality`	8
`TP_entrainement_dual`	25 à 45 min (16×16)	images 64×64	—	9

Durées CPU mesurées sur un ordinateur portable à 16 cœurs ; sur le CPU de Colab (2 cœurs), elles sont nettement plus longues (non vérifié).

Les explications et les questions sont dans l'énoncé ; les notebooks exécutent les calculs et rappellent les formules qu'ils mettent en œuvre. Les réponses sont rédigées dans un compte rendu. Les questions marquées « (à la main) » ne demandent pas d'ordinateur.

Rappels

- *Notations de l'article* : x image propre de densité p, à valeurs dans $[0,1]^d$; t est la *variance* du bruit (le « temps » de la diffusion) : $y = x + \sqrt{t}\,z$, $z \sim \mathcal{N}(0, I_d)$; $p(y \mid t) = \int p(x)\, g_t(y-x)\, dx$ avec g_t la densité de $\mathcal{N}(0, tI)$; énergie $U(y,t) = -\log p(y \mid t)$. Images ImageNet64 en niveaux de gris : $d = 64 \times 64 = 4096$.
- *Gaussienne* : si $z \sim \mathcal{N}(0, I_d)$, $\|z\|^2$ a pour moyenne d et pour variance $2d$; donc $\|z\|/\sqrt{d} \to 1$ avec des fluctuations d'ordre $1/\sqrt{2d}$. L'entropie de $\mathcal{N}(\mu, \Sigma)$ vaut $\frac{1}{2}\log\det(2\pi e\Sigma)$, soit $\frac{d}{2}\log(2\pi e\sigma^2)$ si $\Sigma = \sigma^2 I$.
- *Régression* : $\mathbb{E}\|c - f(y)\|^2$ est minimale pour $f(y) = \mathbb{E}[c \mid y]$, et l'écart à ce minimum vaut $\mathbb{E}\|f(y) - \mathbb{E}[c \mid y]\|^2$.
- *Tweedie–Miyasawa* : $\mathbb{E}[x \mid y] = y + t\nabla_y \log p(y \mid t)$, soit, avec l'énergie, $\nabla_y U(y,t) = \mathbb{E}\left[\frac{y-x}{t} \,\middle|\, y\right]$ et $\hat{x}(y) = y - t\nabla_y U(y,t)$.
- *Équation de la chaleur* : g_t vérifie $\partial_t g_t = \frac{1}{2}\Delta g_t$; par linéarité, $p(\cdot \mid t)$ aussi.
- *PSNR* d'une estimation $\hat{x}$ d'une image $x \in [0,1]^d$: $-10\log_{10}\left(\frac{1}{d}\|x - \hat{x}\|^2\right)$; l'image bruitée a un PSNR d'environ $-10\log_{10} t$ (« PSNR d'entrée »).
- *Estimateur de Hutchinson* : si v a des coordonnées indépendantes valant ± 1, $\mathbb{E}[v^\top A v] = \operatorname{tr} A$.

Graines. Les tirages ont leurs graines fixées dans les notebooks. Faites-les varier : un résultat n'a de valeur que s'il résiste à un changement de graine.

1 Énergie, score et unités

Objectifs

- Situer le problème de la constante de normalisation et ce que le score permet d'éviter.
- Manipuler les unités de l'article (dB/dim, bits/dim) et ordonner les grandeurs.

Modèle d'énergie. Un modèle d'énergie est une fonction $U_\theta : \mathbb{R}^d \to \mathbb{R}$ qui définit la densité $p_\theta(x) = e^{-U_\theta(x)}/Z_\theta$, $Z_\theta = \int e^{-U_\theta(x)}dx$. Le maximum de vraisemblance minimise $\mathrm{NLL}(\theta) = \mathbb{E}_{x\sim p}[-\log p_\theta(x)] = \mathbb{E}_x[U_\theta(x)] + \log Z_\theta$. Le *score* du modèle, $\nabla_x \log p_\theta = -\nabla_x U_\theta$, ne dépend pas de Z_θ ; le *score matching* (Hyvärinen) ajuste ce gradient à celui des données, ce qui, pour des données bruitées, revient à débruiter (Vincent) : c'est l'objectif des modèles de diffusion,

$$\ell_{\mathrm{DSM}}(\theta, t) = \mathbb{E}_{x,y}\left\| \nabla_y U_\theta(y,t) - \frac{y-x}{t} \right\|^2 .$$

Q1 — Ce que la constante de normalisation représente (à la main)

(a) Montrez que $\mathrm{NLL}(\theta) = \mathrm{KL}(p \,\|\, p_\theta) + H(p)$, où $H(p) = \mathbb{E}[-\log p(x)]$ est l'entropie différentielle des données. Que mesure donc la NLL d'un modèle, et pourquoi ne peut-elle descendre sous $H(p)$?

(b) Dans l'expression $\mathbb{E}_x[U_\theta(x)] + \log Z_\theta$, que se passe-t-il si l'on abaisse U_θ sur les données sans toucher au reste ? Quel rôle joue $\log Z_\theta$?

(c) Pourquoi ne peut-on pas calculer Z_θ par une méthode de Monte-Carlo naïve (tirer x uniformément dans $[0,1]^d$ et moyenner $e^{-U_\theta(x)}$) quand $d = 4096$? Vous utiliserez le résultat de la partie 6 : l'ensemble des images naturelles occupe une fraction $10^{-1{,}14\,d}$ du cube.

Unités. L'article exprime les log-probabilités en *décibels par dimension* : $\frac{10}{d}\log_{10} p_\theta(x) = -\frac{10\,U_\theta(x)}{d \ln 10}$. Augmenter de 10 dB/dim revient à multiplier la densité par 10^d. Les NLL se donnent en *bits par dimension*, $\frac{U}{d\ln 2}$, pour un modèle *discret* : une image codée sur 8 bits occupe une case de côté $1/256$, et si l'on suppose la densité constante dans chaque case, $P(\text{case}) = p_\theta(x)\,256^{-d}$.

Q2 — Ordres de grandeur (à la main)

L'article estime que la log-probabilité moyenne des images de test d'ImageNet64 (niveaux de gris) vaut $11{,}4$ dB/dim, c'est-à-dire une entropie différentielle $H(p) \approx -11{,}4$ dB/dim.

(a) Convertissez en bits/dim. Que vaut l'entropie de la loi uniforme sur $[0,1]^d$? Interprétez le signe de $H(p)$ en termes de volume occupé.

(b) Déduisez-en l'entropie discrète des images 8 bits (en bits/dim), puis le nombre « d'images typiques » parmi les 256^d images possibles, pour $d = 4096$.

(c) Entre l'image la plus probable et la moins probable du jeu de test, l'article trouve un écart de 34,4 dB/dim. Quel rapport de probabilités cela représente-t-il ?

Score et débruitage. Pour l'énergie bruitée $U(y,t) = -\log p(y \mid t)$, la formule de Tweedie–Miyasawa s'écrit $\nabla_y U(y,t) = \mathbb{E}[(y-x)/t \mid y]$: le gradient de l'énergie est, au facteur $1/t$ près, le bruit moyen contenu dans y, et $\hat{x} = y - t\nabla_y U$ est le débruiteur optimal. Dans le code des auteurs (`networks/model.py`, classe `EnergyModel`), ce gradient s'appelle `data_score` et l'image débruitée `denoised`.

Q3 — Lire le code (à la main, avec le code)

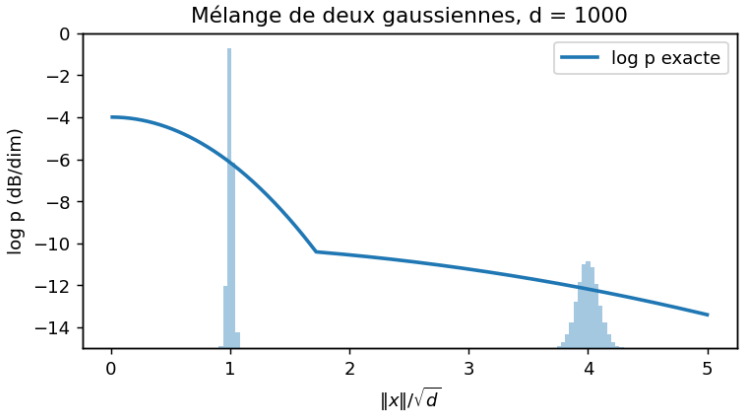
Dans `EnergyModel.forward`, repérez le calcul de `data_score`, de `noise_score` et de `denoised`. `data_score` est-il le score $\nabla_y \log p$ ou son opposé ? Que représente `noise_score` ? Quel argument évite de construire le graphe nécessaire à une seconde dérivation, et quand faut-il ce graphe ?

2 Pourquoi le score ne suffit pas

Objectifs

- Comprendre, sur un exemple où tout se calcule, que le score matching laisse l'énergie indéterminée à une constante près sur chaque région séparée des données, et à chaque niveau de bruit.
- Voir comment passer par les grands bruits relie les régions.

L'exemple de l'article. $p = \frac{1}{2}\mathcal{N}(0, \sigma_1^2 I_d) + \frac{1}{2}\mathcal{N}(0, \sigma_2^2 I_d)$, $\sigma_1 = 1$, $\sigma_2 = 4$, $d = 1000$; 10^5 échantillons. Bruitée, c'est le mélange des $\mathcal{N}(0, (\sigma_k^2 + t)I)$, d'énergie exacte connue (notebook `TP_melange_gaussien`, partie 1).



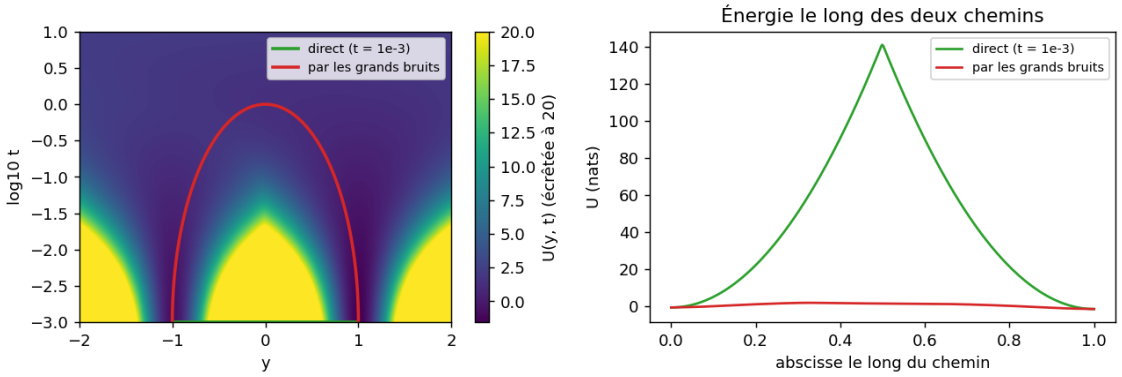
Q4 — Deux coquilles sphériques (à la main)

(a) Où se trouvent les échantillons de chaque composante ? Calculez la moyenne et l'écart-type de $\|x\|/\sqrt{d}$ pour $x \sim \mathcal{N}(0, \sigma^2 I_d)$. Combien d'échantillons s'attend-on à trouver avec $\|x\|/\sqrt{d}$ entre 1,5 et 3,5 ?

(b) Au rayon typique de la composante k, l'autre est négligeable. Montrez qu'alors $U(x) \approx \frac{d}{2}\log(2\pi e\sigma_k^2) + \log 2$, et calculez en dB/dim la log-probabilité typique de chaque composante. Déduisez-en l'écart d'énergie entre les deux coquilles.

(c) Les deux composantes ont le même poids, et pourtant les points de la première sont $10^{6d/10}$ fois plus probables. Expliquez ce paradoxe apparent (il reviendra en partie 6).

Le paysage espace-temps. La figure 1 (droite) de l'article montre, en dimension 1, l'énergie $U(y, t)$ d'un mélange de deux gaussiennes étroites, en fonction de y et de $\log t$ (notebook, partie 2).

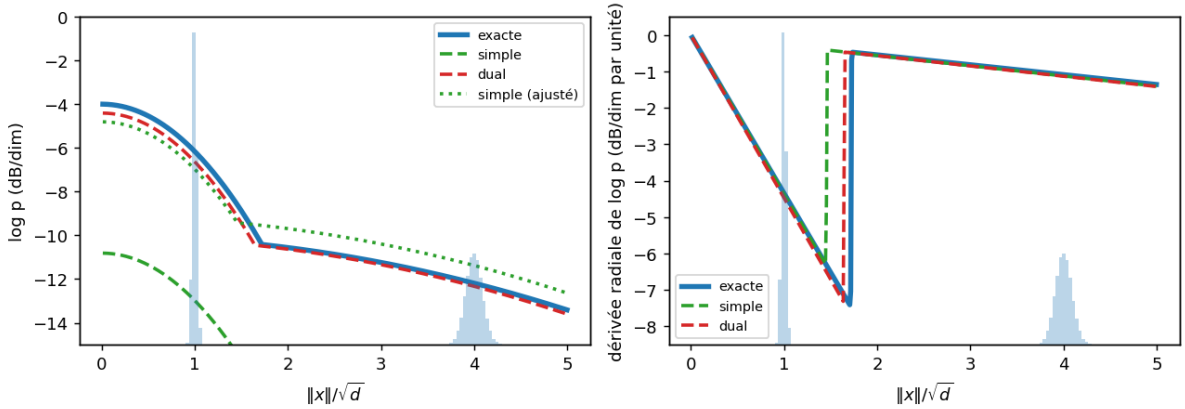


Q5 — Relier les modes par les grands bruits

(a) Relevez l'énergie maximale le long du chemin direct (à $t = 10^{-3}$) et le long du chemin qui monte vers les grands bruits. D'où vient la barrière du premier ?

(b) Si l'on connaissait $\nabla_y U$ et $\partial_t U$ en tout point (y, t), comment calculerait-on $U(y_1, t_1) - U(y_0, t_0)$? Pourquoi le chemin choisi n'importe-t-il pas en théorie, mais beaucoup en pratique, quand ces dérivées sont *apprises* à partir d'échantillons ?

Entraîner. Le notebook (parties 3 et 4) entraîne le petit modèle d'énergie des auteurs (équation (44) : la famille contient l'énergie exacte) par score matching *simple* (terme d'espace seul, à tous les niveaux de bruit $t \in [10^{-2}, 10^{2}]$) puis *dual* (avec le terme de temps de la partie 3). La constante de normalisation est fixée ensuite par l'équation (9), commune aux deux (partie 3).



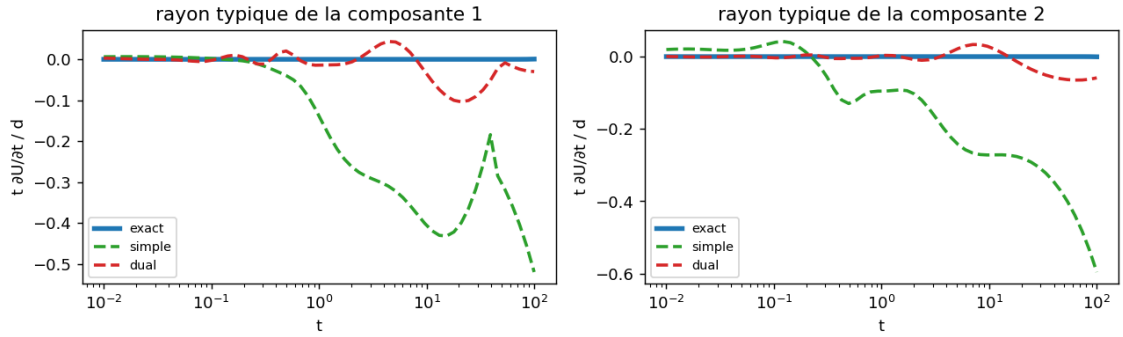
Q6 — Lire la figure 1

(a) Le score appris par score matching simple est-il juste ? Où ? Et l'énergie ? Relevez l'erreur commise sur chaque mode et sur l'écart entre modes, pour les deux méthodes.

(b) Le score matching simple détermine $U(\cdot, t)$ à une constante près pour chaque t, et même, pour t petit, à une constante près sur chaque coquille. Expliquez pourquoi, puis expliquez les deux erreurs observées : sur l'écart entre modes, et sur le niveau global après normalisation à $t_{\max}$.

(c) L'énergie « ajustée » recale la constante globale à l'aide de l'entropie exacte (que l'on ne connaît pas en pratique). Que corrige-t-elle, que ne corrige-t-elle pas ?

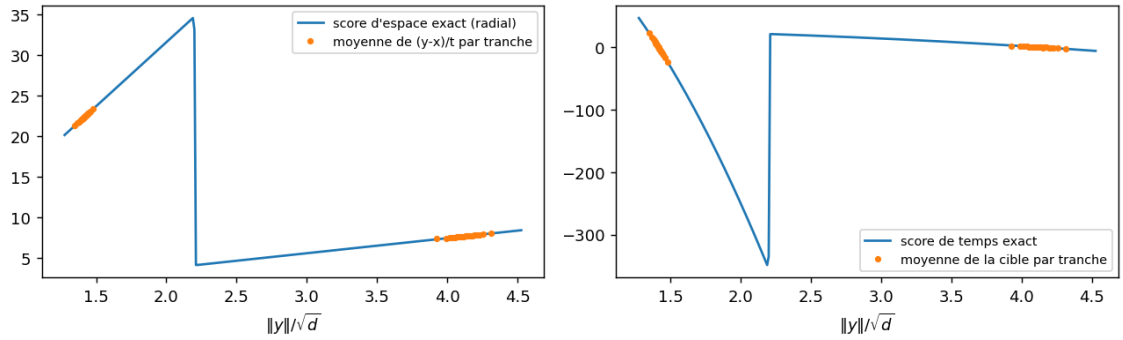
(d) La partie 7 du notebook recommence le score matching simple avec deux autres graines. Que constatez-vous ? Pourquoi le score matching dual ne souffre-t-il pas de ce défaut ?



Q7 — Une cible bruitée

La partie 6 du notebook moyenne, par tranche de rayon de y, les deux cibles de la perte : $(y - x)/t$ (sa composante radiale) et $\frac{d}{2t} - \frac{\|y-x\|^2}{2t^2}$. Que retrouve-t-on, et pourquoi (vous admettrez pour l'instant l'identité (4)

de l'article, démontrée en partie 3) ? Le notebook affiche l'écart-type de la cible de temps et l'amplitude de son espérance : qu'en déduire sur la difficulté d'apprendre le score de temps ?



3 Le score matching dual

Objectifs

- Démontrer l'identité du score de temps et en déduire l'objectif dual de l'article.
- Relier chaque terme de l'article à une ligne du code d'entraînement (`main.py`).
- Comprendre la normalisation par l'équation (9) et ce qui la justifie.

Q8 — L'identité du score de temps (à la main)

(a) En dérivant $p(y \mid t) = \int p(x)\, p(y \mid x, t)\, dx$ par rapport à t, montrez que $\partial_t U(y,t) = \mathbb{E}\big[-\partial_t \log p(y \mid x, t) \,\big|\, y, t\big]$. Comparez avec la démonstration de Tweedie–Miyasawa : qu'est-ce qui change ?

(b) Pour le bruit gaussien, $-\log p(y \mid x, t) = \frac{\|y-x\|^2}{2t} + \frac{d}{2}\log(2\pi t)$. Déduisez-en l'identité (4) de l'article : $\partial_t U(y,t) = \mathbb{E}\big[\frac{d}{2t} - \frac{\|y-x\|^2}{2t^2} \,\big|\, y\big]$, puis l'objectif $\ell_{\text{TSM}}(\theta,t) = \mathbb{E}_{x,y}\big[\big(\partial_t U_\theta(y,t) - \frac{d}{2t} + \frac{\|y-x\|^2}{2t^2}\big)^2\big]$.

(c) Montrez que $\mathbb{E}_{y\sim p(\cdot|t)}[\partial_t U(y,t)] = 0$. Interprétez le signe de $\partial_t U(y,t)$ pour une image y anormalement loin des données (plus loin que ne l'explique le bruit), puis pour une image anormalement proche d'une image propre.

Pondération et objectif final. L'article intègre les deux objectifs sur t. Pour ℓ_{DSM}, le poids « de vraisemblance maximale » $\frac{1}{2}\int_0^\infty \ell_{\text{DSM}}\, dt$ majore $\mathrm{KL}(p \,\|\, \tilde{p}_\theta)$ (équation (6)). Les auteurs tirent $\log t$ uniformément dans $[\log t_{\min}, \log t_{\max}]$ et pondèrent le terme de temps par t^2 ; après division par d, ils ajoutent les deux termes :

$$\ell(\theta) = \mathbb{E}_t\Big[\frac{t}{d}\,\ell_{\text{DSM}}(\theta,t) + \frac{t^2}{d^2}\,\ell_{\text{TSM}}(\theta,t)\Big], \qquad t_{\min} = 10^{-9},\ t_{\max} = 10^{3}. \tag{1}$$

Q9 — De l'équation (8) au code (à la main, avec le code)

(a) Si $\log t$ est uniforme sur $[\log t_{\min}, \log t_{\max}]$, quelle est la densité de t ? Montrez que $\int_{t_{\min}}^{t_{\max}} \ell(t)\, dt = \log\frac{t_{\max}}{t_{\min}}\, \mathbb{E}_t[t\,\ell(t)]$. Que penser de l'équation (7) de l'article ?

(b) En posant $y = x + \sqrt{t}\, z$, montrez que les deux termes de (1) valent $\frac{1}{d}\|\sqrt{t}\,\nabla_y U_\theta - z\|^2$ et $\big(\frac{t}{d}\,\partial_t U_\theta - \frac{1}{2}\big(1 - \frac{\|z\|^2}{d}\big)\big)^2$ (équation (42)). Vérifiez qu'ils sont sans dimension : invariants quand on multiplie les images par a et t par a^2 (que devient alors l'énergie ?).

(c) Retrouvez ces deux termes dans `compute_metrics` (`main.py`). Quels arguments de la ligne de commande (`models/*/args.json`) produisent exactement (1) ? Comment les niveaux de bruit sont-ils tirés (classe `UniformLog`, fichier `noise.py`) ?

(d) *(priorité réduite)* Que vaut chacun des deux termes pour un réseau qui ne débruite pas du tout ($\hat{x} = y$) et dont l'énergie ne dépend pas de t ? Comparez aux pertes du notebook `TP_melange_gaussien` (partie 3).

Normalisation. Les deux objectifs ne déterminent U_θ qu'à une constante près. Comme $p(y \mid t_{\max}) \approx \mathcal{N}(m, t_{\max} I)$ quand $t_{\max}$ est grand devant la variance des images, les auteurs fixent la constante par

$$U_\theta(y,t) \longrightarrow U_\theta(y,t) - \mathbb{E}_y\big[U_\theta(y,t) \mid t = t_{\max}\big] + \frac{d}{2}\log(2\pi e\, t_{\max}). \tag{2}$$

Q10 — Pourquoi une seule constante suffit (à la main)

(a) Montrez que l'équation de la chaleur $\partial_t p(y \mid t) = \frac{1}{2}\Delta_y p(y \mid t)$ entraîne que $\int p(y \mid t)\, dy$ ne dépend pas de t. Si U_θ a les bonnes dérivées, que dire de $Z_\theta(t) = \int e^{-U_\theta(y,t)} dy$? Pourquoi est-ce indispensable à (2) ?

(b) Quelle erreur commet-on en remplaçant l'entropie de $p(y \mid t_{\max})$ par $\frac{d}{2}\log(2\pi e\, t_{\max})$? Majorez-la à l'aide de l'entropie de la gaussienne de même covariance, $\frac{1}{2}\sum_i \log\big(2\pi e(\lambda_i + t_{\max})\big)$ (λ_i : valeurs propres de la covariance des images, de somme $d\,\sigma^2$ avec $\sigma^2 \approx 0{,}065$), pour $t_{\max} = 10^3$.

(c) *(priorité réduite)* En partant de l'équation de la chaleur, montrez que $U = -\log p$ vérifie l'équation de Hamilton–Jacobi $\partial_t U = \frac{1}{2}\Delta_y U - \frac{1}{2}\|\nabla_y U\|^2$ (équation (35)). Le score de temps est donc une fonction du score d'espace : pourquoi l'apprendre séparément ?

4 L'architecture : une énergie construite sur un débruiteur

Objectifs

- Comprendre pourquoi l'article définit l'énergie comme un produit scalaire, et sous quelles hypothèses son gradient redonne le réseau de départ.
- Vérifier ces hypothèses sur le réseau entraîné, et en tirer les conséquences.

L'idée. Plutôt que d'inventer une architecture d'énergie, les auteurs partent d'un réseau de score $s_\theta : \mathbb{R}^d \times \mathbb{R} \to \mathbb{R}^d$ dont on connaît les qualités (un UNet de débruitage) et posent

$$U_\theta(y,t) = \tfrac{1}{2}\langle y, s_\theta(y,t)\rangle. \tag{3}$$

L'espoir est que $\nabla_y U_\theta \approx s_\theta$, de sorte que le réseau d'énergie hérite des biais inductifs du débruiteur. Le UNet des auteurs (annexe C.1 de l'article, `networks/unet.py`) n'a aucun biais additif ; ses normalisations sont des normalisations d'instance « homogènes » (équation (41)) ; les ReLU sont remplacées par des GELU, pour que U_θ soit deux fois dérivable ; t entre par un encodage de Fourier suivi d'un perceptron, qui module le gain de chaque canal après chaque normalisation, $x_c \mapsto (1 + \langle w_c, e(t)\rangle)\, x_c$.

Q11 — Gradient d'un produit scalaire (à la main)

(a) Montrez que, sans hypothèse sur s_θ, $\nabla_y U_\theta = \frac{1}{2}\big(s_\theta + \nabla_y s_\theta^\top y\big)$, où $\nabla_y s_\theta$ est la matrice jacobienne de s_θ par rapport à y.

(b) s_θ est *homogène* si $s_\theta(\lambda y, t) = \lambda s_\theta(y,t)$ pour tout $\lambda \geq 0$, *conservatif* s'il est le gradient d'une fonction scalaire. Montrez que l'homogénéité entraîne $\nabla_y s_\theta\, y = s_\theta$ (identité d'Euler) et la conservativité la symétrie de $\nabla_y s_\theta$; concluez que $\nabla_y U_\theta = s_\theta$ sous les deux hypothèses.

(c) Montrez que si s_θ est homogène, $U_\theta(\lambda y, t) = \lambda^2 U_\theta(y,t)$. Que vaut alors $U_\theta(0,t)$, et que vaut $\log p_\theta(0)$, la log-probabilité de l'image noire, en fonction de la constante de normalisation C ? Est-ce plausible pour la vraie énergie $U(0,t) = -\log p(0 \mid t)$?

(d) D'autres auteurs utilisent $U_\theta = \frac{1}{2}\|s_\theta\|^2$. Calculez son gradient. Pourquoi ne préserve-t-il pas, selon l'article, les propriétés du réseau de score ?

Le réseau des auteurs. Le notebook `TP_reseau_energie` charge le réseau d'énergie en niveaux de gris (parties 1 à 4). Le gradient et la sortie du UNet sont calculés par autograd sur 8 images, propres ou bruitées.

Q12 — Le réseau entraîné vérifie-t-il les hypothèses ?

(a) Relevez la formule calculée, le nombre de paramètres, le nombre de couches, la présence de biais, les largeurs. Comparez à l'annexe C.1 de l'article.

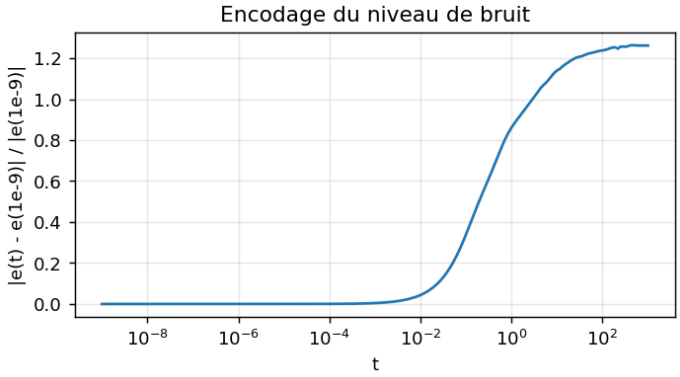
(b) L'identité de la Q11(a) est-elle vérifiée ? Et $\nabla_y U_\theta \approx s_\theta$? Pour quels niveaux de bruit ?

(c) Le réseau est-il homogène ? Relevez $U_\theta(\lambda y)/(\lambda^2 U_\theta(y))$. Quelles couches peuvent rompre l'homogénéité ? Pourquoi l'entraînement pousserait-il le réseau à la rompre ?

(d) Relevez la log-probabilité de l'image noire à différents t. Conforme à la Q11(c) ?

(e) Que conclure de l'argument de l'article (annexe B.2) ? Les auteurs écrivent (annexe C.1) que, pour cette raison, il faut calculer $\nabla_y U_\theta$ et non utiliser s_θ. Que serait-il arrivé si l'on avait débruité avec $\hat{x} = y - t\, s_\theta(y,t)$?

Le réseau utilise-t-il t ? L'encodage de t est $(\cos \omega_k t, \sin \omega_k t)_{k \le 32}$, les fréquences ω_k étant régulièrement espacées en échelle logarithmique entre $1/t^{\text{enc}}_{\text{max}}$ et $1/t^{\text{enc}}_{\text{min}}$ (`sinusoidal_embedding`, `networks/conditioning.py`).



Q13 — Un réseau aveugle aux faibles bruits

(a) Quelles valeurs de $t^{\text{enc}}_{\text{min}}$ et $t^{\text{enc}}_{\text{max}}$ le code utilise-t-il ? Et l'article (annexe C.1) ? Expliquez la forme de la courbe de l'encodage.

(b) Le notebook débruite des images de PSNR d'entrée 40 dB ($t = 10^{-4}$) en donnant au réseau un t faux. Que devient la qualité de $y - t_{\text{vrai}} \nabla_y U_\theta$? Qu'en concluez-vous sur le rôle de t pour $t \le 10^{-2}$? Comment le réseau peut-il néanmoins débruiter ?

(c) Pourquoi $y - t_{\text{donné}} \nabla_y U_\theta$, elle, se dégrade-t-elle ?

5 Valider le modèle

Objectifs

- Reproduire le tableau 1 (débruitage) et comprendre ce qu'il prouve.
- Tester la cohérence des deux scores et de la normalisation, ce que l'article ne fait pas directement.
- Comprendre ce que mesure une NLL et pourquoi les valeurs du tableau 2 se comparent mal.

Débruitage. Le tableau 1 compare, en couleur, le réseau d'énergie et un réseau de score de même architecture entraîné par score matching ordinaire (sortie $y - t\, s_\theta(y,t)$). Le notebook `TP_reseau_energie` (partie 5) affiche les valeurs enregistrées par les auteurs dans leurs points de contrôle et les recalcule sur 32 images de validation (profil CPU).

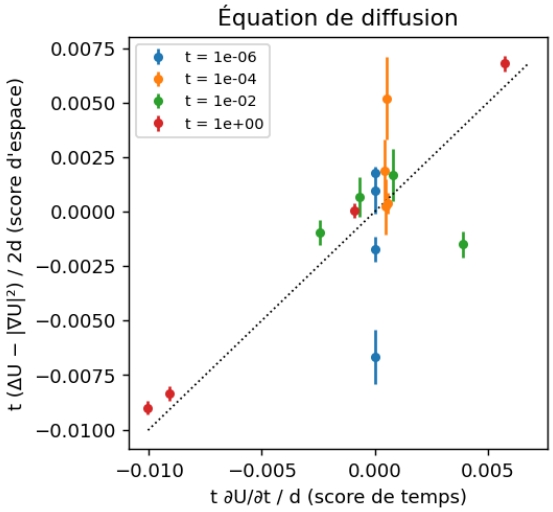
Q14 — Le réseau d'énergie débruite-t-il aussi bien ?

(a) Les valeurs enregistrées dans les points de contrôle sont-elles celles du tableau 1 ? Les valeurs recalculées en sont-elles proches ? Attention à l'en-tête du tableau 1 : que contient vraiment sa première ligne ?

(b) Où le réseau d'énergie est-il meilleur, où est-il moins bon ? L'écart à -30 dB a-t-il un sens ?

(c) Pourquoi un bon débruitage à tous les niveaux de bruit est-il une condition nécessaire d'une bonne énergie (rappelez l'équation (6)) ? Est-ce une condition suffisante ?

Cohérence des deux scores. L'énergie exacte vérifie l'équation de Hamilton–Jacobi $\partial_t U = \frac{1}{2}\Delta_y U - \frac{1}{2}\|\nabla_y U\|^2$ (Q10). Le notebook (partie 6) compare les deux membres pour le réseau, multipliés par t/d, sur 4 images (laplacien estimé avec 8 sondes de Hutchinson).



Q15 — Le réseau vérifie-t-il l'équation de diffusion ?

(a) Pour quels niveaux de bruit les deux membres sont-ils égaux aux barres d'erreur près ? Le notebook affiche séparément $\frac{t}{2d}\Delta U_\theta$ et $\frac{t}{2d}\|\nabla U_\theta\|^2$: quel est leur ordre de grandeur, comparé à l'écart ?

(b) Que vaut $\frac{t}{d}\partial_t U_\theta$ pour $t \le 10^{-4}$? Rapprochez de la Q13 et de la remarque de l'article sur le comportement de l'énergie sous $t_{\min}$.

(c) Pourquoi faut-il une double rétropropagation pour calculer $v^\top \nabla^2 U_\theta\, v$? Combien d'évaluations du réseau coûte l'estimation du laplacien avec k sondes ?

Normalisation. Le notebook (partie 7) recalcule la constante de (2) sur 128 images de validation à plusieurs « $t_{\max}$ », avec l'entropie de la gaussienne isotrope ($\frac{d}{2}\log 2\pi e t$) ou celle de la gaussienne de même covariance que y.

Q16 — La masse est-elle conservée ?

(a) Comparez la constante recalculée à $t = 10^3$ à celle des auteurs (5 844,9 nats). D'où vient l'écart ?

(b) Comment évolue la constante quand t diminue, avec l'entropie isotrope ? avec l'entropie de la gaussienne de même covariance ? Qu'en concluez-vous sur la conservation de la masse au cours de la diffusion ? Pourquoi le test n'a-t-il plus de sens pour $t = 0{,}1$?

(c) Quelle erreur sur $\log p_\theta$ (en dB/dim) une erreur de 2 nats sur la constante entraîne-t-elle ?

NLL. Le tableau 2 de l'article compare des NLL en bits/dim sur ImageNet64, en couleur ; celle du modèle (3,36) est obtenue en une seule évaluation par image, $\text{NLL} = 8 + \frac{U_\theta(x,0)}{d\ln 2}$. Le notebook `TP_log_probabilites`

(partie 2) la recalcule sur 1 000 images (profil CPU).

Q17 — Comparer des NLL

(a) Quelle valeur obtenez-vous ? Avec quelle constante ?

(b) L'article énumère trois facteurs qui peuvent déplacer une NLL de 0,5 bits/dim ou plus : lesquels ? Pour chacun, dites dans quel sens il joue pour le modèle de l'article.

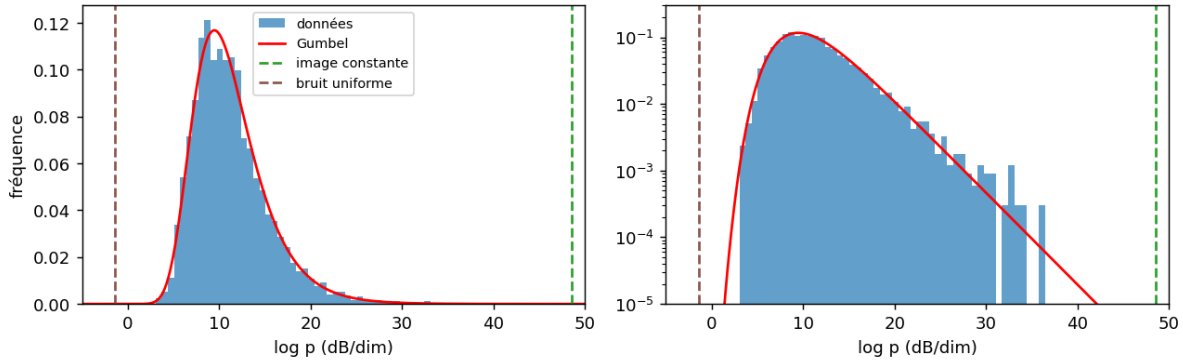
(c) Les NLL des modèles de diffusion (I-DDPM, VDM) sont des « majorants », celles des flots (Glow, TarFlow) sont « exactes », celle de l'article une « estimation ». Expliquez la différence. Laquelle se compare à une entropie ?

6 Quelle est la probabilité d'une image ?

Objectifs

- Calculer et interpréter la distribution des log-probabilités des images (figure 3).
- Comprendre l'absence de concentration, en comparant à un modèle gaussien.
- Relier la probabilité au contenu : contraste, luminosité, parcimonie (figure 4).

Le calcul. Le notebook `TP_log_probabilites` évalue $\log p_\theta(x) = -U_\theta(x, 0)$ (une seule passe du réseau en niveaux de gris) sur 5 000 images de validation (profil CPU ; 50 000 sur GPU) et compare le résultat aux valeurs que les auteurs ont calculées pour les 50 000 images (`outputs/energies_test.pt`).



Q18 — La distribution des log-probabilités

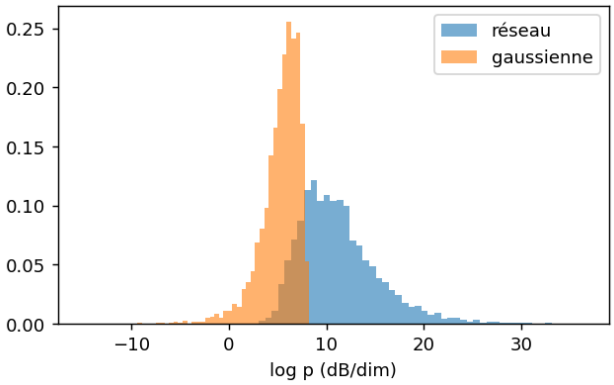
(a) Nos valeurs coïncident-elles avec celles des auteurs ? D'où peut venir un écart de près de 1 dB/dim sur certaines images ?

(b) Relevez la moyenne, l'écart-type, les extrêmes, l'entropie discrète, et les paramètres de la loi de Gumbel. Comparez à l'article et à la Q2.

(c) Où se situent l'image constante la plus probable et le bruit uniforme ? Le bruit uniforme est-il moins probable que toutes les photographies ? Que vaut $\log p_\theta$ de l'image noire, et pourquoi (Q11) ?

(d) L'histogramme est asymétrique : de quel côté est la queue lourde ? Que dit l'article (section 3.2) d'un modèle qui donnerait une loi de Gumbel ?

Absence de concentration. Le notebook (partie 7) ajuste une gaussienne (moyenne et covariance empiriques de 20 000 autres images) et compare ses log-probabilités sur les images et sur ses propres échantillons.



Q19 — Pourquoi un facteur $10^{14\,000}$?

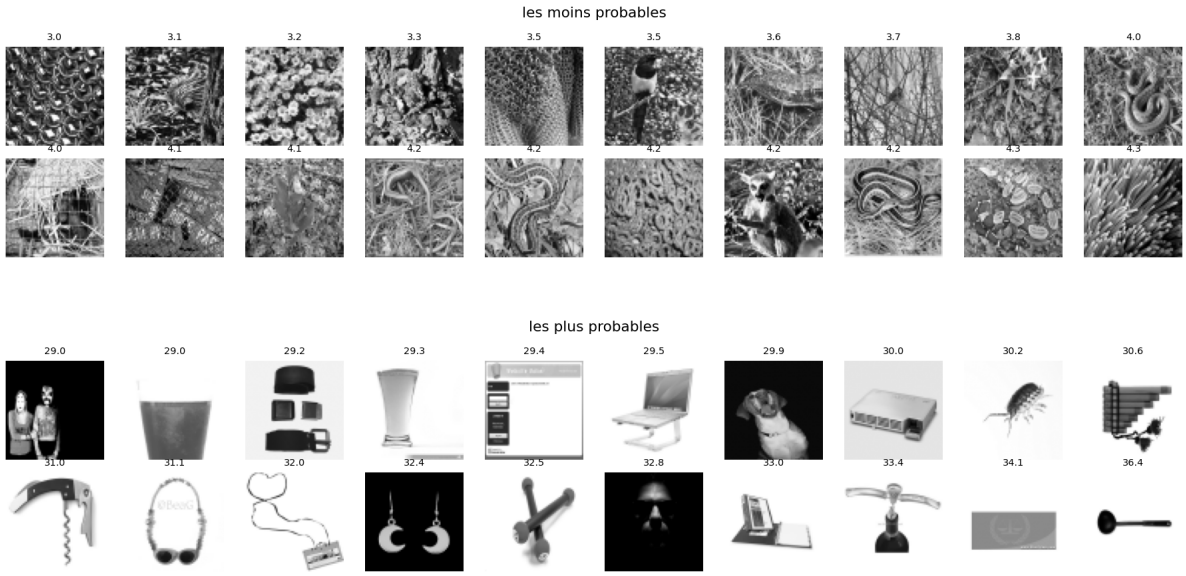
(a) (À la main.) Pour $x \sim \mathcal{N}(\mu, \Sigma)$ en dimension d, montrez que $-\log p(x)$ a pour écart-type $\sqrt{d/2}$ nats. Convertissez en dB/dim pour $d = 4096$ et comparez à la valeur du notebook pour les échantillons de la gaussienne.

(b) Comparez avec l'écart-type des log-probabilités des *images*, selon la gaussienne et selon le réseau. Qu'en déduire sur la structure de la loi des images ?

(c) Laquelle des deux lois donne la plus grande probabilité moyenne aux images ? Qu'est-ce que cela signifie ?

(d) Les images les moins probables ont une densité $10^{14\,000}$ fois plus faible que les plus probables, et pourtant on en trouve autant dans le jeu de données. Expliquez (Q4).

Contenu des images. Le notebook (partie 4) affiche les images les moins et les plus probables, et les 15 images de référence des auteurs.



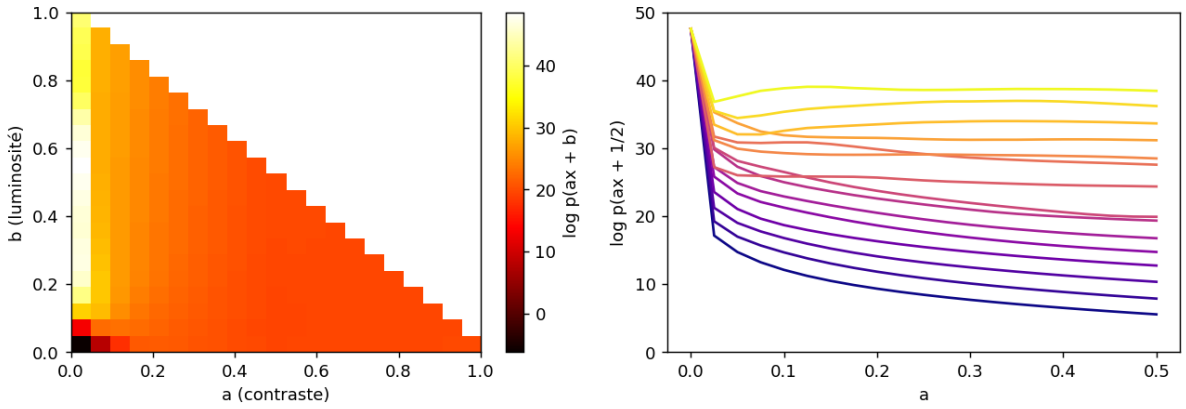
Q20 — Qu'est-ce qu'une image probable ?

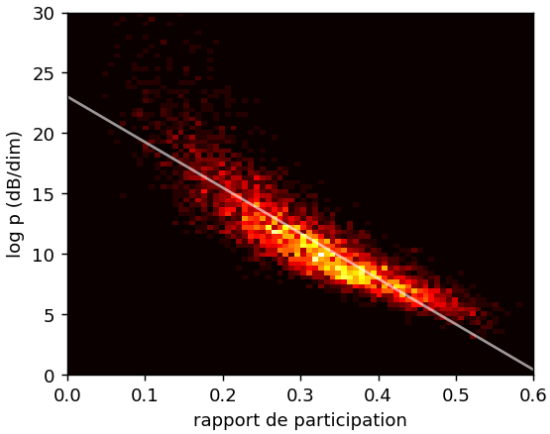
(a) Décrivez les images des deux extrémités. L'énergie d'une image, exprimée en bits, est la longueur de son code optimal : interprétez.

(b) (Notebook, parties 5 et 6.) Comment la log-probabilité varie-t-elle avec la luminosité b et avec le contraste a de $ax + b$? Que vaut la pente moyenne de $\log p(ax + \frac{1}{2})$? Que se passe-t-il entre $a = 0$ et le premier contraste non nul ? L'article en déduit que le support de la loi est « étoilé » : expliquez.

(c) Le notebook calcule $U_\theta(ax)/(a^2 U_\theta(x))$ pour $a = 0{,}5$ et 2 : comparez à la Q12. Pourquoi une énergie quadratiquement homogène serait-elle incompatible avec la courbe de (b) ?

(d) Quelle part de la variance de $\log p$ le rapport de participation des coefficients d'ondelettes explique-t-il ? Dans quel sens ? Pourquoi est-ce attendu ?



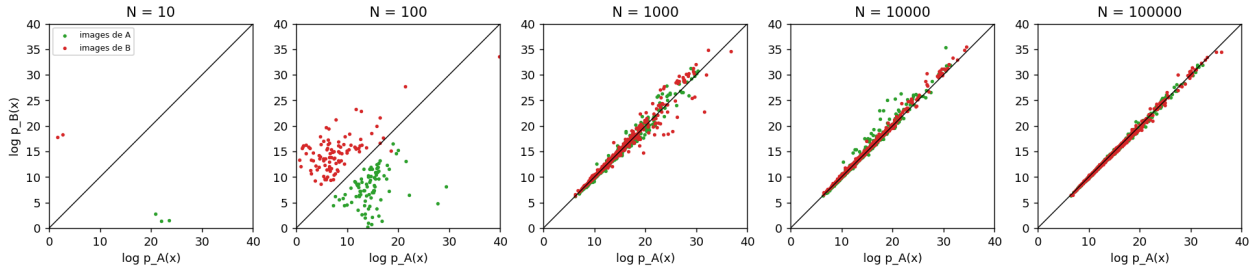


7 Deux réseaux, mêmes probabilités ?

Objectifs

- Reprendre le test de généralisation « forte » de [2] pour un modèle d'énergie.
- Distinguer variance et biais du modèle, et comprendre ce qu'une petite erreur relative sur l'énergie signifie en grande dimension.

L'expérience. Les auteurs séparent les images d'entraînement d'ImageNet64 (couleur) en deux sous-ensembles disjoints A et B et entraînent un réseau d'énergie sur N images de chacun, pour $N = 1$ à 10^5 ; puis ils comparent les log-probabilités que les deux réseaux donnent aux mêmes images. Les poids ne sont pas distribués, mais les énergies le sont : le notebook `TP_log_probabilites` (partie 8) trace la figure 2 à partir d'elles.



Q21 — Mémorisation puis généralisation

(a) Relevez l'écart quadratique moyen entre $\log p_A$ et $\log p_B$ et leur corrélation en fonction de N. À partir de quel N les deux réseaux s'accordent-ils ? Comparez au nombre d'exemples que demanderait une estimation sans a priori en dimension $d = 12\,288$.

(b) Pour $N \leq 100$, le notebook compare la log-probabilité que le réseau A_N donne à ses images d'entraînement et à d'autres images. Interprétez. Pourquoi, selon les auteurs, la transition vers la généralisation s'accompagne-t-elle d'une augmentation de la variance des énergies sur le jeu d'entraînement ?

(c) Les deux réseaux s'accordent pour $N = 10^5$: cela prouve-t-il que leurs probabilités sont justes ?

(d) D'après l'article (annexe A.4), pour un mélange de deux classes uniformes sur des ensembles de volumes $V_i \sim r_i^d$ et de fréquences f_i, montrez que $U_i = d \log r_i - \log f_i$. Quelle précision sur $\log p$ (en dB/dim) faudrait-il pour estimer des fréquences à 10 % près en dimension $d = 4096$? Comparez à l'écart entre les réseaux A et B.

8 La dimension locale du paysage d'énergie

Objectifs

- Définir une dimension effective qui dépend de l'image et de l'échelle, de deux façons équivalentes.
- Mesurer cette dimension et la confronter à l'hypothèse d'une variété de petite dimension.

Deux définitions. Autour d'une image x, à l'échelle $\sqrt{t}$, l'article définit

$$d_{\text{eff}}(x,t) = \frac{1}{t}\,\mathbb{E}_y\big[\|x - \mathbb{E}[x \mid y]\|^2 \,\big|\, x\big] \quad (11) \qquad \text{et} \qquad d_{\text{eff}}(x,t) = d - 2t\,\partial_t\,\mathbb{E}_y\big[U(y,t) \mid x\big] \quad (12), \quad (4)$$

avec $y = x + \sqrt{t}\,z$. La première compte les directions dans lesquelles le débruiteur optimal laisse passer le bruit ; la seconde mesure la vitesse à laquelle la probabilité autour de x se dilue quand on ajoute du bruit.

Q22 — Trois exemples (à la main)

(a) p est une masse ponctuelle en x_0. Que vaut $d_{\text{eff}}(x_0, t)$?

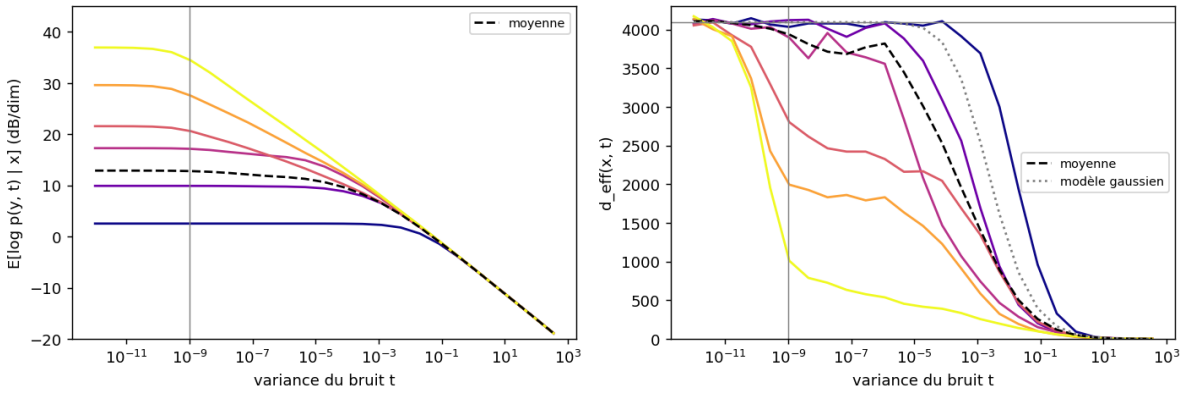
(b) p est la loi uniforme sur un sous-espace affine de dimension k (une « variété » plate, de mesure infinie). Calculez $\mathbb{E}[x \mid y]$, puis d_{eff} par (11), puis $\mathbb{E}_y[U(y,t) \mid x]$ et d_{eff} par (12).

(c) $p = \mathcal{N}(\mu, \Sigma)$, de valeurs propres λ_i. Calculez $d_{\text{eff}}(x,t)$ par (11) ; dépend-elle de x ? Montrez que sa moyenne sur $x \sim p$ vaut $\sum_i \frac{\lambda_i}{\lambda_i + t}$. Interprétez les limites $t \to 0$ et $t \to \infty$, et le fait que la dimension dépende de l'échelle.

Q23 — Équivalence des deux définitions (à la main, difficile)

En dérivant $\mathbb{E}_y[U(y,t) \mid x] = \int g_t(y-x)U(y,t)\,dy$ par rapport à t, et en utilisant l'équation de la chaleur pour g_t, l'équation de Hamilton–Jacobi (Q10) et le lemme de Stein ($\mathbb{E}[\langle y - x, h(y)\rangle \mid x] = t\,\mathbb{E}[\nabla \cdot h(y) \mid x]$ pour $y \sim \mathcal{N}(x, tI)$), montrez que (11) et (12) coïncident pour l'énergie exacte. Pour un modèle, que faut-il pour qu'elles coïncident ?

Mesures. Le notebook `TP_dimension_effective` calcule, pour 6 des 15 images de référence des auteurs (profil CPU) et 25 niveaux de bruit, l'énergie effective et la dimension effective par (11), avec 4 réalisations du bruit, ainsi que la courbe moyenne sur 32 autres images et celle du modèle gaussien.



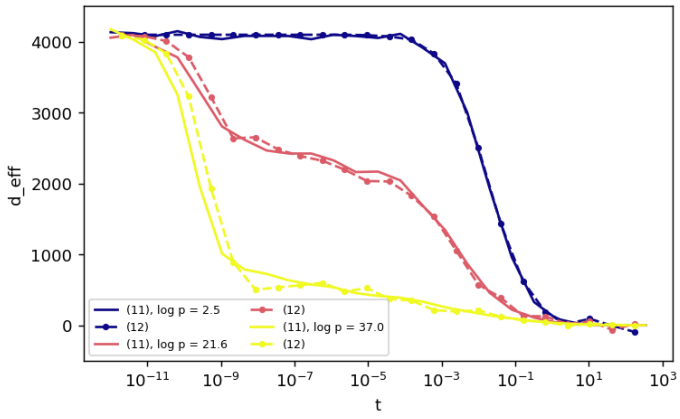
Q24 — Lire la figure 5

(a) Décrivez l'énergie effective en fonction de t. Vers quoi convergent toutes les courbes aux grands bruits, et pourquoi ?

(b) Relevez d_{eff} pour l'image la moins probable, la plus probable, la moyenne et le modèle gaussien, à quelques échelles. Que dire de l'hypothèse d'une « variété » de petite dimension ? Comment cela s'accorde-t-il avec la Q19(d) ?

(c) Pour t inférieur à $t_{\min} = 10^{-9}$, d_{eff} remonte à d pour toutes les images. Pourquoi ? Que dire de la diminution momentanée de d_{eff} vers 10^{-5} que signale l'article ?

(d) Nos courbes coïncident-elles avec celles des auteurs (figure de la partie 5 du notebook) ? Avec 4 réalisations du bruit au lieu de 1 000, pourquoi l'estimation est-elle déjà précise ?



Q25 — Les deux définitions sur le réseau, et la log-probabilité retrouvée

(a) Les estimations de d_{eff} par (11) et par (12) (différences finies de l'énergie effective) coïncident-elles ? Qu'est-ce que cela confirme ?

(b) Le notebook (partie 4) reconstruit $\log p(x)$ par l'équation (16), à partir des seules erreurs de débruitage. Comparez à l'évaluation directe. En théorie, (16) donne un majorant de $-\log p$: est-ce le cas ? Pourquoi la comparaison au modèle lui-même ne permet-elle pas de le vérifier ?

9 Pour aller plus loin : entraîner

Objectifs

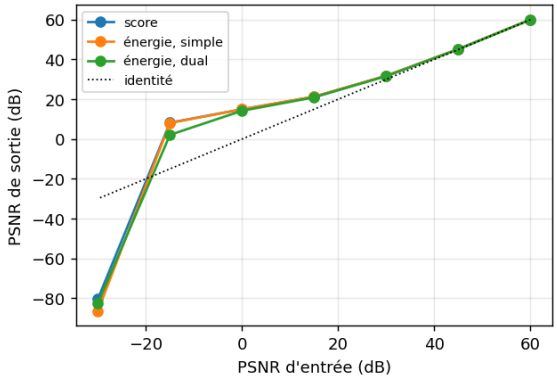
- Entraîner soi-même, avec le code des auteurs, un réseau de score, un réseau d'énergie par score matching simple et le même par score matching dual.
- Mesurer le coût de la double rétropropagation et observer ce que le terme de temps change sur des images.

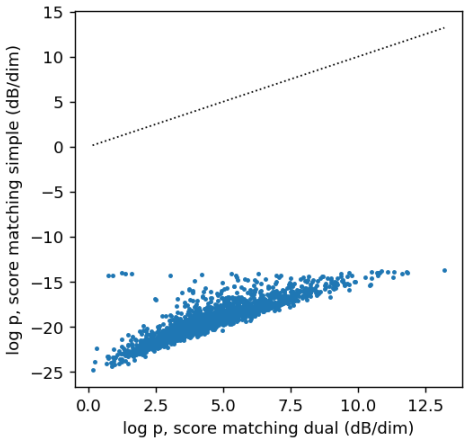
Le notebook. `TP_entrainement_dual` entraîne les trois réseaux, de même architecture, sur les 45 000 premières images de validation d'ImageNet64 et les évalue sur les 5 000 dernières. Sur CPU, la version jouet travaille sur des images réduites à 16×16, avec un petit UNet (0,2 million de paramètres), des bruits de variance 10^{-5} à 10^{2} et 8 000 itérations ; sur GPU, la version réaliste sur des images 64×64, avec la plage de bruit des auteurs (10^{-9} à 10^{3}) et 20 000 itérations.

Q26 — Le prix de l'énergie

(a) Relevez la durée d'une itération pour chaque réseau. Expliquez le rapport : combien de passes avant et arrière chaque itération demande-t-elle ? Comparez au rapport donné par l'article (120 h contre 32 h).

(b) En contrepartie, combien coûte $\log p_\theta(x)$ une fois le réseau entraîné, comparé aux méthodes qui intègrent le score d'un modèle de diffusion ?





Q27 — Simple ou dual sur des images

(a) Comparez le débruitage des trois réseaux. Le terme de temps nuit-il au débruitage ?

(b) Comparez, pour les deux réseaux d'énergie, la constante $C(t)$ recalculée à plusieurs niveaux de bruit, et leur NLL de test. Comparez aussi au modèle gaussien. Relisez la Q6 : retrouvez-vous les deux défauts du score matching simple ?

(c) Les deux réseaux d'énergie classent-ils les images de la même façon (corrélation des log-probabilités) ? Qu'est-ce qui distingue alors leurs énergies ?

(d) L'équation de diffusion est-elle mieux vérifiée par le réseau dual que par le réseau simple ?

Bilan

- Le score matching (débruitage) détermine l'énergie à une fonction du temps près, et, quand le support des données est fait de régions séparées, à une constante près sur chacune ; le score de temps, appris par une régression analogue, relie les niveaux de bruit et, par les grands bruits, toutes les régions (parties 2 et 3).

- Avec ses deux scores, l'énergie est déterminée à une seule constante près, fixée là où la loi bruitée est presque gaussienne ; la masse est alors conservée au cours de la diffusion, ce que l'on vérifie à quelques nats près (parties 3 et 5).
- L'énergie $\frac{1}{2}\langle y, s_\theta\rangle$ construite sur un UNet débruite aussi bien que le UNet seul, mais le réseau entraîné n'est ni homogène ni tel que $\nabla U_\theta = s_\theta$, contrairement à ce qui motive cette architecture ; et il ignore t aux faibles bruits (partie 4).
- Les log-probabilités des images s'étalent sur des dizaines de dB/dim, selon une loi proche de Gumbel, en fonction du contenu (contraste, parcimonie) : il n'y a pas de concentration, et une densité élevée signifie un petit volume, pas une image fréquente (parties 6 et 7).
- Deux réseaux entraînés sur 10^5 images différentes donnent la même probabilité à chaque image à 0,2 dB/-dim près (partie 7).
- La dimension effective du voisinage d'une image dépend de l'image et de l'échelle, de presque 0 à presque d : l'hypothèse d'une variété de petite dimension est trop simple (partie 8).

Références

[1] F. Guth, Z. Kadkhodaie, E. P. Simoncelli, *Learning normalized image densities via dual score matching*, NeurIPS 2025 (arXiv:2506.05310).

[2] Z. Kadkhodaie, F. Guth, E. P. Simoncelli, S. Mallat, *Generalization in diffusion models arises from geometry-adaptive harmonic representations*, ICLR 2024.

[3] A. Hyvärinen, *Estimation of non-normalized statistical models by score matching*, JMLR, 2005 ; P. Vincent, *A connection between score matching and denoising autoencoders*, Neural Computation, 2011.

[4] Y. Song, C. Durkan, I. Murray, S. Ermon, *Maximum likelihood training of score-based diffusion models*, NeurIPS 2021 ; D. Kingma et al., *Variational diffusion models*, NeurIPS 2021.

[5] S. Mohan, Z. Kadkhodaie, E. P. Simoncelli, C. Fernandez-Granda, *Robust and interpretable blind image denoising via bias-free convolutional neural networks*, ICLR 2020.

[6] X. Kong, R. Brekelmans, G. Ver Steeg, *Information-theoretic diffusion*, ICLR 2023.

[7] L. Theis, A. van den Oord, M. Bethge, *A note on the evaluation of generative models*, ICLR 2016.

[8] E. Nalisnick et al., *Do deep generative models know what they don't know?*, ICLR 2019.

[9] S. Lyu, E. P. Simoncelli, *Nonlinear extraction of independent components of natural images using radial gaussianization*, Neural Computation, 2009.

[10] Y. Wu, S. Verdú, *MMSE dimension*, IEEE Trans. Information Theory, 2011.

[11] P. Chrabaszcz, I. Loshchilov, F. Hutter, *A downsampled variant of ImageNet as an alternative to the CIFAR datasets*, arXiv:1707.08819, 2017.